حذف تگهای زاید دریافتی از متون MS-Word

عنوان: **حذف تگهای** نویسنده: وحید نصیری

ویسنده. وحید کشیری تاریخ: ۱۷:۳۷:۲۰ ۱۳۸۷/۰۸/۱۱ آدرس: www.dotnettips.info

برچسبها: Regular expressions

یکی از مشکلاتی که من همیشه با کاربران عادی دارم بحث انتقال مطالب از Word مایکروسافت به ادیتورهای WYSWING تحت وب است. برای مثال شما سایت یوپایی را درست کردهاید که کاربران میتوانند مطالب آنرا ویرایش یا کم و زیاد کنند.

اگر مطلب از ابتدا در این نوع ادیتورها تایپ و آماده شود هیچ مشکلی وجود نخواهد داشت چون خروجی اکثر آنها استاندارد است، اما متاسفانه خروجی وب word بسیار مشکلزا است (copy/paste معمولی مطالب آن در یک ادیتور تحت وب) و خصوصا برای نمایش تایپ فارسی در وب اصلا مناسب نیست. یعنی هیچ الزامی وجود ندارد که اندازه فونتها در متن نهایی نمایش داده شده در وب یکسان باشند یا خطوط در هم فرو نروند و یا عدم تناسب اندازه قلم متن صفحه با قلم استفاده شده در CSS سایت (که شکل ناهماهنگ و غیرحرفهای را حاصل خواهد کرد) و امثال آن. اینجاست که کار شما زیر سؤال میرود! "این برنامه درست کار نمیکنه! متن من بههم ریخته شده و امثال این"

این کاربر عادی عموما یک تایپیست است یا یک منشی که به او گفته شده است شما از امروز موظفید مطالبی را در این سایت قرار دهید. بنابراین این کاربر حتما از word استفاده خواهد کرد (برای پیش نویس مطالب). همچنین عموما هم مرورگر "سازمانی" مورد استفاده، هنوز که هنوز است همان IE است (در اکثر شرکتها و خصوصا ادارات) و مهم نیست که الان آخرین نگارش IE یا فایرفاکس و تمام هیاهوهای مربوطه به کجا ختم شدهاند. حتما باید سایت با IE هم سازگار باشد. بنابراین از برنامه IE tester غافل نشوید.

و دست آخر شما هم نمیتوانید به کاربر عادی ثابت کنید که این خروجی وب word اصلا استاندارد نیست (حتما کار شما است که مشکل دارد نه شرکت معظم مایکروسافت!). یا اینکه به آنها بگوئید اصلا مجاز نیستید در وب همانند یک فایل word از چندین نوع قلم مختلف فارسی غیراستاندارد استفاده کنید چون ممکن است کاربری این نوع قلم مورد استفاده شما را نداشته باشد و نمایش نهایی به هم ریخته تر از آنی خواهد بود که شما فکرش را میکنید! یا اینکه با استفاده از این روش حجم نهایی صفحه حداقل 50 کیلو بایت بیشتر خواهد شد (بدلیل حجم بالای تگهای زاید word) و نباید کاربران دایال آپ را فراموش کرد.

مدتی در اینباره جستجو کردم و نتیجه حاصل این بود که تمامی روشها به یک مورد ختم میشود: حذف تگهای غیراستاندارد word هنگام دریافت مطلب و پیش از ذخیره سازی آن در دیتابیس

یک سری از ادیتورهای متنی تحت وب مانند FCK editor این قابلیت را به صورت خودکار اضافه کردهاند و حتی اگر کاربر متنی را از word در آنها Paste کند پیغامی را در همین رابطه دریافت خواهد کرد (شکل زیر) و البته کاربر میتواند گزینه لغو یا خیر را نیز انتخاب کند و دوباره همان وضعیت قبل تکرار خواهد شد. (یا حتی دکمه مخصوص کپی از word را هم به نوار ابزار خود اضافه کردهاند)

برای این منظور تابع زیر تهیه شدهاست که من همواره از آن استفاده میکنم و تا به امروز مشکل پاسخ پس دادن به کاربران عادی را به این صورت حل کردهام!

این تابع تمامی تگهای اضافی و غیراستاندارد word متن دریافتی از یک ادیتور wyswing را حذف میکند و به این صورت متن نهایی نمایش داده شده در سایت، تابع CSS مورد استفاده در سایت خواهد شد و نه حجم بالایی از تگهای غیراستاندارد word. (ممکن است کاربر در ابتدا کمی جا بخورد ولی مهم نیست! سایت باید استاندارد نمایشی خودش را از CSS آن دریافت کند و نه از تگهای (word)

```
using System.Text.RegularExpressions;
/// <summary>
/// Removes all FONT and SPAN tags, and all Class and Style attributes.
/// Designed to get rid of non-standard Microsoft Word HTML tags.
/// </summary>
public static string CleanMSWordHtml(string html)
{
    try
    {
        // start by completely removing all unwanted tags
```

```
html = Regex.Replace(html, @"<[/]?(font|span|xml|del|ins|[ovwxp]:\w )[^>]*?>", "",
RegexOptions.IgnoreCase);
// then run another pass over the html (twice), removing unwanted attributes

html = Regex.Replace(html, @"<([^>]*)(?:class|lang|style|size|face|[ovwxp]:\w
)=(?:'[^']*'|""[^""]*""|[^\s>])([^>]*)>", "<$1$2>", RegexOptions.IgnoreCase);

html = Regex.Replace(html, @"<([^>]*)(?:class|lang|style|size|face|[ovwxp]:\w
)=(?:'[^']*'|""[^""]*""|[^\s>])([^>]*)>", "<$1$2>", RegexOptions.IgnoreCase);

return RemoveHTMLComments(html);
         }
         catch
         {
                return html;
         }
  }
  public static string RemoveHTMLComments(string html)
         try
                 Regex _Regex = new Regex("((<!-- )((?!<!-- ).)*( -->))(\r\n)*", RegexOptions.Singleline);
                 return _Regex.Replace(html, string.Empty);
         catch
                return html;
         }
  }
```

متد RemoveHTMLComments را عمدا جدا قرار دادم تا مشخص تر باشد. پس از تمیزکاری اولیه، ممکن است دسته گلهای تیم مایکروسافت به صورت کامنت باقی بمانند که باید آنها را هم تمیز کرد! :)

نظرات خوانندگان

نویسنده: Shaho

تاریخ: ۲:۲۶:۰۰ ۱۳۸۷/۰۸/۱۷

اقا خيلي مرسي!

نویسنده: سیدمحمدرضا فخری

تاریخ: ۲۰:۲۰/۸۸۳۱ ۲۱:۲۰:۲۱

سلام. خیلی ممنون از این کد بسیار مفید. اما یک مطلب و آن اینکه عبارت class=MsoNormal با این تابع حذف نمیشه. ممنون میشم بفرمائید چه تغییری در کد بدهیم.

نویسنده: وحید نصیری

تاریخ: ۱۴:۲۴:۱۹ ۱۳۸۸/۰۲/۳۱

class ها و lang|style|size|face|[ovwxp باید حذف بشه. ولی اگر روش فوق راضی کننده نبود از روش مقاله زیر هم میتوان استفاده کرد:

http://www.codinghorror.com/blog/archives/000485.html

یک روش دیگر هم این است که کلا هرچی تگ html است را یکجا حذف کرد. روش کار به صورت زیر است: http://gibbons.co.za/archive/2005/01/28/249.aspx

> نویسنده: سیدمحمدرضا فخری تاریخ: ۲۰/۳۰/۳۸۹ ۱۱:۴۵:۰۹

سلام. با تشکر از شما، برنامه مربوط به کدینگ هارور رو قبلا تست کردم، مشکل داشت. کدی شکه شما زحمت کشیدید هم غیر از مسئله ذکر شده درکامنت اول، خوب کار میکرد فقط مشکل اینست که اختصاصی به فرمت های ورد ندارد و همه استایل ها را پاک میکند که برای ما بعنوان یک بلاگ سرویس قابل استفاده نیست، چون کاربران پس از کپی پیست، استایل های خودشان را هم اضافه میکنند و این کد همه را پاک میکند. اگر برنامه بود که فقط بتواند اضافات ورد را پاک کند خوب بود. و اینکه بصورت جاوا اسکریپت باشد تا بتوان درکلاینت هم از آن استفاده کرد(من متاسفانه رگولار اکسپرشن را عمیق کار نکرده ام، همین رگولاررا میتوان در جاوا هم بکار برد؟).

نویسنده: وحید نصیری تاریخ: ۲/۴۶:۳۷ ۱۳۸۸/۰۳/۰۲

سلام،

بله در حالت جاوا اسکریپتی توسط FCK-Editor هم کار شده که میشود از آن ایده گرفت: http://dev.fckeditor.net/browser/FCKeditor/trunk/editor/dialog/fck paste.html

به تابع CleanWord آن در صفحه فوق مراجعه نمائید.

نویسنده: سیدمحمدرضا فخری تاریخ: ۱۴:۱۹:۴۸ ۱۳۸۸/۰۳/۰۲

ممنون

عنوان: استخراج آدرسهای ایمیل از یک متن

نویسنده: وحید نصیری

تاریخ: ۲۰:۵۰:۴۸ ۱۳۸۷/۰۸/۲۷ www.dotnettips.info

برچسبها: Regular expressions

در قسمت اول بررسی نحوه برنامه نویسی افزونه outlook ، در مورد استفاده از regular expressions اندکی توضیح داده شد. امروز مثالی دیگر از همین دست را بررسی خواهیم کرد.

چند روز قبل یک ایمیل تبلیغاتی به دست من رسید که فرد ارسال کننده انبوهی از ایمیلها را در قسمت To قرار داده بود (بجای قسمت BCC (رونوشت مخفی)).

خوب، برای جدا کردن انبوهی از ایمیلهای مخلوط با سایر متون چه باید کرد؟ چند ساعت وقت گذاشت و تک تک آنها را به صورت دستی جدا کرد؟ (برای ذخیره سازی در یک دیتابیس برای مثال :))

یا برای مثال برنامههای download manager توانایی استخراج لینکهای موجود در یک متن کپی شده در حافظه را دارند. آنها به چه صورتی عمل میکنند؟ چگونه میتوانند لینکها را با دقتی بالا و بسیار سریع از لابلای متن موجود تشخیص دهند؟

بهینهترین و سریعترین راه برای این نوع جستجوها استفاده از کتابخانه <u>regular expressions</u> (عبارات با قاعده) در دات نت فریم ورک است. اگر نیاز به یک برگه تقلب (!) در این زمینه داشتید میتوانید به اینجا مراجعه کنید. همچنین در همان سایت، کاربران بسیاری را خواهید یافت که الگوهای ابداعی خود را با دیگران به اشتراگ میگذارند.

برای مثال فرض کنید فایلی را که حاوی مخلوطی از متن و ایمیل است را در یک رشته بارگذاری کردهاید. نحوه استخراج ایمیلهای موجود با استفاده از این امکانات به صورت زیر خواهد بود:

```
using System.IO;
using System. Text. Regular Expressions;
using System.Text;
class CRegEx
    /// <summary>
    استخراج ایمیلهای یک فایل متنی و ذخیره آن در فایلی جدید ///
    /// </summary>
    /// <param name="inFilePath">فایل ورودی</param>
// <param name="outFilePath">فایل خروجی</param>
public static void ExtractEmails(string inFilePath, string outFilePath)
          string data = File.ReadAllText(inFilePath); /خواندن فايل متنى
| ايجاد شيء عبارت با قاعده بر اساس الگوى تشخيص ايميلها
| Regex emailRegex = new Regex(@"\w+([-+]\w+)*\@\\w+([-.]\w+)*\.\w+([-.]\w+)*",
          RegexOptions.IgnoreCase);
//اییدا کردن گروه تطابق یافته با الگوی ما
MatchCollection emailMatches = emailRegex.Matches(data);
          ایجاد شُیء اَسْترینگ بیلدر برای ذخیره سازی سریع اطلاعات دریافتی//
StringBuilder sb = new StringBuilder();
          ذخیره ایمیلهای استخراج شده//
          foreach (Match emailMatch in emailMatches)
                 sb.AppendLine(emailMatch.Value);
           ذخیره کردن اطلاعات استخراج شده در فایلی جدید//ُ
          File.WriteAllText(outFilePath, sb.ToString());
    }
}
```

راستی، اگر روزی خواستید تعداد بالایی ایمیل ارسال کنید، آنها را به قسمت bcc اضافه کنید (Message.Bcc.Add)، در قالب یک ایمیل، نه چند هزار ایمیل متوالی (در طی یک حلقه برای مثال). به این صورت (استفاده از قسمت BCC) میل سرور تمام آدرسها را در صف قرار خواهد داد و متحمل بار اضافی شدید نخواهد شد. در این حالت اگر میل باکس خود را چک کنید شاید بلافاصله ایمیل

مورد نظر را دریافت نکنید. نگران نباشید، انجام عملیات در صف قرار گرفته و در طی دقایق و یا حتی ساعات بعدی پردازش خواهد شد (بسته به بار سرور).

چند نکته را باید در اینجا در نظر داشت. حتما آدرسهای اضافه شده را با استفاده از عبارات باقاعده یکبار پیش از اضافه شدن بررسی نمائید (Regex.IsMatch). در صورتیکه یکی از ایمیلها فرمت غیراستانداردی داشته باشد کل کار برگشت خواهد خورد. و همچنین باید دقت داشت که برای این موضوع حد نصاب وجود دارد. بر روی یکی از میل سرورهای یک هاست ایرانی تست کردم، حداکثر 100 رونوشت مخفی را بیشتر قبول نمیکرد. بنابراین هر بار میشود 100 ایمیل را به صورت یکجا ارسال کرد (که باز هم از روش استفاده از حلقهای که 100 بار ایمیل میزند بسیار بهتر است و هاست دار به علت ایجاد بار اضافی شدید بر روی سرور با شما تماس نخواهد گرفت)

چگونه Regex سریعتری داشته باشیم؟

وحيد نصيري

عنوان:

نویسنده: تاریخ:

www.dotnettips.info آدرس:

برچسبها: Regular expressions

نکاتی را در هنگام کار با عبارات با قاعده در دات نت باید رعایت نمود تا بتوان به حداکثر کارآیی و سرعت دست یافت:

-1 ایجاد اشیاء Regex هزینه بر هستند. برای مثال اگر متد شما که در آن شیء Regex را ایجاد کردهاید مرتبا فراخوانی میشود، این شیء را به صورت یک متغیر محلی خارج از بدنه تابع تعریف کنید. یا به همین صورت هرگز در یک حلقه اشیاء Regex را بارها و بارها اىحاد نكنىد.

-2از گزینه RegexOptions.Compiled استفاده کنید. با اینکار زمانیکه برنامه شما اجرا می شود، عبارت باقاعده در حافظه کامپایل شده و به بهبود کارآیی 30 درصدی دست خواهید یافت. اگر از این گزینه استفاده نشود، هر بار که شیء Regex مورد استفاده قرار می گیرد، عبارت باقاعده شما همانند یک اسکرییت باید مجددا تفسیر شود.

-3 اشیاء Regex را از نوع static readonly تعریف کنید تا بازهم کارآیی را افزایش دهید (اشیایی ثابت در زمان اجرا و همچنین اشارهگری هستند به آن شیء و نه مقدار آن).

خلاصه موارد فوق:

private static readonly Regex _valueFormatMatch = new Regex(@"[0-9]", RegexOptions.Compiled);

بعلاوه اگر نمیخواهید Regex شما هر بار در حین اجرای برنامه (در اولین باری که برنامه بارگذاری میشود)، کامپایل شود، مىتوانيد آنرا به درون یک اسمبلی نیز کامپایل کنید (Precompilation). روش انجام اینکار را در این مقاله میتوانید مشاهده نمائيد.

```
عنوان: عبارات باقاعدهای در مورد کار با تگها
نویسنده: وحید نصیری
تاریخ: ۱۳۸۸/۰۵/۰۱
آدرس: www.dotnettips.info
```

حذف تمامی تگهای یک عبارت HTML

برچسبها: Regular expressions

این تابع و عبارت باقاعده به کار رفته در آن هنگام جستجو بر روی یک فایل html که حاوی انبوهی از تگها است میتواند مفید باشد و یا جهت حذف هر نوع فرمت اعمالی به یک متن.

```
private static readonly Regex _htmlRegex = new Regex("<.*?>", RegexOptions.Compiled);
/// <summary>
/// </summary>
/// 
/// 
/// 
/// 
/// 
/// 
/// 
/// creturns>
/// creturns>
public static string CleanTags(string html)
{
    return _htmlRegex.Replace(html, string.Empty);
}
```

حذف یک تگ ویژه بدون حذف محتویات آن

فرض کنید میخواهید تمام تگهای script بکار رفته در یک محتوای html را حذف کنید.

```
private static readonly Regex _contentRegex = new Regex(@"<\/?script[^>]*?>", RegexOptions.Compiled | RegexOptions.IgnoreCase);

/// <summary>
/// </summary>
/// </summary>
/// </summary>
/// </param name="html">ورودی اچ تی ام ال </param>
/// </param name="html">ورودی اچ تی ام ال </param>
/// 
public static string CleanScriptTags(string html)

{
    return _contentRegex.Replace(html, string.Empty);
}
```

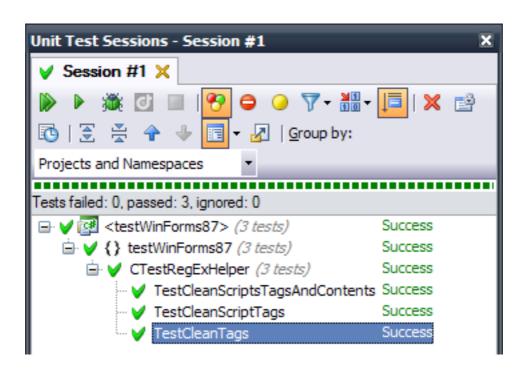
حذف یک تگ خاص به همراه محتویات آن تگ

فرض کنید میخواهیم در محتوای html دریافتی اثری از تگها و کدهای جاوا اسکریپتی یافت نشود.

و اگر فرض کنیم که متدهای فوق در کلاسی به نام CRegExHelper قرار گرفتهاند، کلاس آزمون واحد آن به صورت زیر میتواند باشد:

```
using NUnit.Framework;
```

```
namespace testWinForms87
   [TestFixture]
   public class CTestRegExHelper
  #region Methods (3)
  // Public Methods (3)
        [Test]
       public void TestCleanScriptsTagsAndContents()
            Assert.AreEqual(
                CRegExHelper.CleanScriptsTagsAndContents("data1 <script> ... </script> data2"), "data1 data2");
       }
       [Test]
       public void TestCleanScriptTags()
            Assert.AreEqual(
                CRegExHelper.CleanScriptTags("<b>data1</b> <script> ... </script> data2"),
"<b>data1</b> ... data2");
       }
       [Test]
       public void TestCleanTags()
            Assert.AreEqual(
                CRegExHelper.CleanTags("<b>data</b>"),
                "data");
  #endregion Methods
}
```



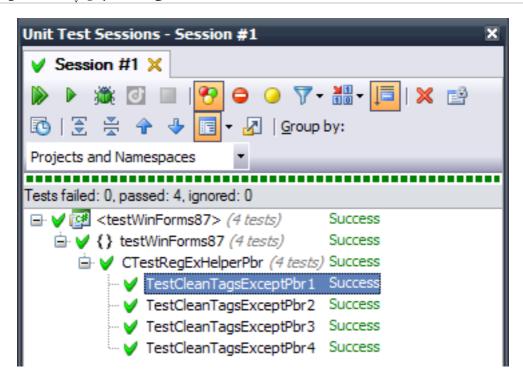
عنوان: ح**ذف تمامی تگها منهای چند تگ خاص از HTML دریافتی** نویسنده: وحید نصیری تاریخ: ۲۱:۱۲:۰۰ ۱۳۸۸/۰۶/۰۵ تاریخ: www.dotnettips.info

برچسبها: Regular expressions

در ادامه مطلب " عبارات باقاعدهای در مورد کار با تگها " ، عبارت باقاعده مربوطه به حذف تمامی تگها برای فرمت زدایی یک متن بسیار جالب است اما مشکلی را که به وجود خواهد آورد، از بین بردن سطرهای موجود است. به عبارت دیگر با استفاده از این عبارت با قاعده، کل متن در امتداد یک سطر قرار میگیرد. اکنون میخواهیم تمامی تگها منهای دو تگ مربوط به p و br و خف شوند. چه باید کرد؟

و اگر بخواهیم یک سری تست برای آن بنویسیم به موارد زیر میتوان اشاره کرد:

```
using NUnit.Framework;
namespace testWinForms87
   [TestFixture]
   public class CTestRegExHelperPbr
       [Test]
       public void TestCleanTagsExceptPbr1()
           Assert.AreEqual(
                CRegExHelper.CleanTagsExceptPbr("<b>data1</b><br/>data2"),
                "data1<br/>data2");
       }
       [Test]
       public void TestCleanTagsExceptPbr2()
           Assert.AreEqual(
                CRegExHelper.CleanTagsExceptPbr("<b>data1</b><br>data2"),
                "data1<br>data2");
       }
       [Test]
       public void TestCleanTagsExceptPbr3()
           Assert.AreEqual(
                CRegExHelper.CleanTagsExceptPbr("<b>data1</b><br/>data2"),
"data1<br/>data2");
       }
       [Test]
       public void TestCleanTagsExceptPbr4()
           Assert.AreEqual(
                CRegExHelper.CleanTagsExceptPbr("<b>data1</b>data2<br />"),
"data1data2<br />");
       }
   }
}
```



نظرات خوانندگان

نویسنده: mdpdotnet **۲۳:۲۷:۴**∘ **۳**\λ/∘۶/∘۵ تاریخ: در مورد Regex ای که نوشتید یه توضیحی میدید ؟ من زیاد با رجکس ها جور نیستم.تازه دارم یاد میگیرم. (: نویسنده: وحید نصیری ۰۰:۲۰:۳۵ ۱۳۸۸/۰۶/۰۶ تاریخ: سلام یک debug visualizer برای VS.Net هست به نام Regular Expression Visualizer. با VS2005 و 2008 سازگار است. آنرا از آدرس زیر دریافت کنید: http://weblogs.asp.net/rosherove/archive/2005/11/26/AnnoucingRegexKit10.aspx سپس فایلهای dll آنرا در یکی از مسیرهای زیر بسته به نگارش vs.Net خودتون کیی کنید: My Documents\Visual Studio 2008\Visualizers My Documents\Visual Studio 2005\Visualizers اكنون در VS.Net روى سطر return _pbrRegex يک breakpoint بگذاريد و نتيجه را ملاحظه كنيد. یک مثال عملی: http://professionalaspnet.com/archive/2008/06/18/Regular-Expression-Visualizer.aspx برای نمونه خروجی عبارت باقاعده مثال جاری به صورت زیر است که کمک شایانی است در درک عبارت فوق و امثال آن: > zero-width negative lookahead br or br/ р or p/ **End Capture** (any character). (one or more times) (non-greedy) + <

> نویسنده: DotNetCoders تاریخ: ۸۱:۳۶:۴۹ ۱۳۸۸/۰۶/۰۶

ممنون جناب نصيرى فقط من با اين بخش آخر رجكس مشكل دارم.

این بخش منظورمه :

<?+.

معنیش چیه؟

اگه کتاب کامل و مفید یا منبع خوبی بهم معرفی کنید خودم پیدا میکنم وقت شما رو هم نمیگیرم.

نویسنده: وحید نصیری تاریخ: ۶/۰۶°/۱۳۸۸ ۲:۴۳:۴۰

- لطفا سه چهار سطر آخر پاسخ ارسال شده بنده را مرور بفرمائید.
 - کتاب خوب هم، همه اینرا توصیه میکنند:

Mastering Regular Expressions از O'Reilly Media که تا به حال سه edition از آن منتشر شده.

تبدیل زیرنویسهای خاص پلورالسایت به فرمت SRT

نویسنده: وحید نصیری

عنوان:

تاریخ: ۱۸:۳۵ ۱۳۹۲/۰۱/۰۹

آدرس: www.dotnettips.info

گروهها: Regular expressions, SubtitleTools, Html Agility Pack

یک سری از دورههای پلورالسایت دارای زیرنویس هستند که تحت عنوان Transcript در کنار آنها قرار گرفتهاند:



Building Applications with ASP.NET MVC 4

This course is a comprehensive introduction to ASP.NET MVC 4, and will give you the essentials you need to start building applications with Microsoft's MVC framework.



این زیرنویسها فرمت ویژهای دارند:

در آن، هر 1i که دارای کلاسی به نام transcript-clip است، حاوی یک div میباشد و این div دارای تعدادی لینک است. این لینکها توسط ویژگی datas آنها که بیانگر زمان شروع گفتگو است، مشخص میشوند و همینطور الی آخر. بنابراین اگر بخواهیم برای آنها ساختاری را تهیه کنیم، به کلاسهای ذیل خواهیم رسید:

هر 11 دارای کلاس transcript-clip، یک شیء TranscriptClip را تشکیل میدهد. هر شیء TranscriptClip میتواند داری چندین TranscriptItem باشد. برای استخراج این اطلاعات، یکی از بهترین ابزارها، کتابخانه HTML Agility pack است که توسط آن میتوان به 11های یاد شده دسترسی یافت:

```
var nodes = doc.DocumentNode.SelectNodes("//li[@class='transcript-clip']/div");
```

و سپس اطلاعات آنها را استخراج نمود.

```
using System;
using System.Collections.Generic;
using System.Globalization; using System.IO;
using System.Linq;
using System.Text;
using System.Text.RegularExpressions;
using System.Web;
using HtmlAgilityPack;
namespace PluralsightTranscripts
{
   public class TranscriptClip
       public string Title { set; get; }
       public IList<TranscriptItem> TranscriptItems { set; get; }
   public class TranscriptItem
       public double StartTime { set; get; }
       public string Text { set; get; }
   public class ExtractSubtitle
       public static void ConvertToSrt(string fileName)
           var transcriptClips = extractItems(fileName);
           var itemNumber = 1;
           foreach (var item in transcriptClips)
               transcriptClipToSrt(item, itemNumber);
               itemNumber++;
       private static void transcriptClipToSrt(TranscriptClip item, int itemNumber)
           var count = item.TranscriptItems.Count;
           var srtFileContent = transcriptItemsToSrt(item.TranscriptItems, count);
           var fileName = removeIllegalCharacters(string.Format("{0}-{1}.srt",
itemNumber.ToString("00"), item.Title));
           File.WriteAllText(fileName, srtFileContent);
       private static string transcriptItemsToSrt(IList<TranscriptItem> items, int count)
           var lineNumber = 1;
           var sb = new StringBuilder();
           for (int row = 0; row < count; row++)
               sb.AppendLine(lineNumber.ToString(CultureInfo.InvariantCulture));
               sb.AppendLine(getTimeLine(items, count, row));
               sb.AppendLine(items[row].Text);
               sb.AppendLine(string.Empty);
               lineNumber++;
           return sb.ToString();
       }
       private static string getTimeLine(IList<TranscriptItem> items, int count, int row)
           var startTs = TimeSpan.FromSeconds(items[row].StartTime);
           var endTs = row + 1 < count ? TimeSpan.FromSeconds(items[row + 1].StartTime) :</pre>
private static string timeSpanToString(TimeSpan lineTs)
```

```
return string.Format("{0}:{1}:{2},{3}", lineTs.Hours.ToString("D2"), lineTs.Minutes.ToString("D2"), lineTs.Seconds.ToString("D3"));
        private static string removeIllegalCharacters(string fileName)
            string regexSearch = string.Format("{0}{1}"
                                                 new string(Path.GetInvalidFileNameChars()),
                                                 new string(Path.GetInvalidPathChars()));
            var r = new Regex(string.Format("[{0}]", Regex.Escape(regexSearch)));
            return r.Replace(fileName, ".");
        private static IList<TranscriptClip> extractItems(string fileName)
            var htmlContent = File.ReadAllText(fileName);
            var results = new List<TranscriptClip>();
            var doc = new HtmlDocument
            1
                OptionCheckSyntax = true,
                OptionFixNestedTags = true,
                OptionAutoCloseOnEnd = true,
                OptionDefaultStreamEncoding = Encoding.UTF8
            doc.LoadHtml(htmlContent);
            var nodes = doc.DocumentNode.SelectNodes("//li[@class='transcript-clip']/div");
            foreach (var node in nodes)
                var itemsList = new List<TranscriptItem>();
                var title = node.ParentNode.ChildNodes.First(x => x.Name == "a").InnerText;
                foreach (var childNode in node.ChildNodes)
                    if (childNode.Name != "a") continue;
                    var dataS = childNode.Attributes.First(x => x.Name == "data-s");
                    itemsList.Add(new TranscriptItem
                         StartTime = double.Parse(dataS.Value)
                         Text = HttpUtility.HtmlDecode(childNode.InnerText.Trim())
                     });
                }
                results.Add(new TranscriptClip { TranscriptItems = itemsList, Title = title });
            return results;
        }
    }
}
```

اگر این اطلاعات را کنار هم قرار دهیم، به کلاس کمکی فوق خواهیم رسید. کار با گرههای 1i شروع میشود. سپس در این گرهها، کلیه گرههای a یا لینکها، یافت شده و سپس datas و متن آنها استخراج میشوند. اگر اینها را نهایتا کنار هم قرار دهیم، میتوان به فرمت SRT متداول که اکثر یخش کنندههای فایلهای تصویری قادر به یردازش آنها هستند، رسید.

فرمت SRT ساختار سادهای دارد. هر گفتگوی آن حداقل از سه سطر تشکیل میشود. سطر اول یک شماره خود افزاینده است. سطر دوم زمان شروع و پایان گفتگو را مشخص میکند و سطر سوم بیانگر متن گفتگو است. برای مثال:

```
1
00:00:01,636 --> 00:00:05,616
Hi, this is Scott Allen and this is the first module in the course design
```

دریافت پروژه کامل این مطلب
PluralsightTranscripts.zip

نظرات خوانندگان

نویسنده: الهام تاریخ: ۹/۰/۱۳۹۲/ ۲۲:۲۱

سلام آقای نصیری

آیا شما عضو سایت پلورال سایت هستید؟ چقدر پرداخت کردید و این مبلغ را چطور با توجه به وضع ایران واریز کردید؟ آیا ارزش عضو شدن رو داره؟

ببخشید چون من دانشجو هستم و بدنبال یادگیری حرفه ای برنامه نویسی و زبانم هم خوبه میخواستم از منابع انگلیسی استفاده کنم.

ىا تشكر

نویسنده: وحید نصیری تاریخ: ۹ ۰/۱ ۱۳۹۲ ۲۲:۳۴

سلام؛ من عضو نيستم.

نویسنده: حسین تاریخ: ۱۳۹۲/۰/۱۳۱:۰

این زیرنویسها فقط برای اعضای اون سایت در دسترسه.از کجا میشه بهشون دسترسی پیدا کرد ؟

نویسنده: وحید نصی*ری* تاریخ: ۱/۱۰ ۱/۱۹ ۱:۰

لطفا روی لینک مطرح شده در سطر اول مطلب فوق کلیک کنید . کل بحث جاری در مورد استخراج اطلاعات و تبدیل فرمت خاص صفحه وبی بود که ملاحظه میکنید. این صفحه هم عمومی است (هر چند ظاهر سادهای دارد، اما پشت صحنه و سورس آن، متن زمانبندی شده کل دوره است).

> نویسنده: علیرضا جهانشاهلو تاریخ: ۱۲۱۴ ۱۳۹۲/۰ ۲:۴۰

اتفاقا سایت Lynda هم از همین روش استفاده میکنه و من با کمی تغییر موفق شدم که فایلهای Transcript آموزشی هاشو استخراج کنم.

ممنون مهندس

نویسنده: سیروان عفیفی تاریخ: ۱۵:۴۳ ۱۳۹۲/۰۷/۲۷

ظاهراً ساختار عوض شده به این شکل (البته در اینجا data-s حذف شده و مقدار آن به صورت رشته ایی در انتهای مقدار -ng click اضافه شده است به صورت (start=39.796) :

<a href="javascript:void(0)" ng-click="launchPlayerWindow('http://pluralsight.com/training',
'author=scott-allen&name=mvc4-building-m1-intro&mode=live&clip=0&course=mvc4-building');">Introduction


```
نویسنده: وحید نصیری
تاریخ: ۱۷:۲۱ ۱۳۹۲/۰۷/۲۷
```

- البته من عضو نيستم و به نظر جديدا عنوان كردند «Sorry, transcripts are only available to subscribers».

- در کدهای فوق، فقط این چند سطر باید تغییر کنند:

```
نویسنده: پویان
تاریخ: ۱۲۹/۰/۱۳۹۳ ۱۶:۲۴
```

با سلام

الان که حتما باید در سایت plural sight عضو باشیم راهی نیست تا زیرنویس بگیریم ؟ ایا شما زیرنویس بعضی از فیلمها را دارید ؟

```
ٔ
نویسنده: وحید نصیری
تاریخ: ۱۶:۳۸ ۱۳۹۳/۰ ۱۶:۳۸
```

فایل تورنت پیوست شده حاوی مثالها و زیرنویسهای 52 دوره هست: srt only.zip

```
عنوان: دریافت زمانبندی شده به روز رسانیهای آنتی ویروس Symantec به کمک کتابخانههای Quartz.NET و Quartz.NET و Quartz.NET به کمک کتابخانههای Quartz.NET بسیروان عفیفی نویسنده: ۸:۳۰ ۱۳۹۲/۰۴/۰۳ میروان عفیفی میروان عفیفی آنریخ: میروان عفیفی میروان عفیفی میروان عفیفی آنریخ: میروان عفیفی میروان عفیفی میروان عفیفی میروان عفیفی میروان عفیفی آنریخ: میروان عفیفی میروان میروان عفیفی میروان میروان عفیفی میروان میروان عفیفی میروان میروا
```

در این رابطه اَقای راد در دو قسمت به صورت مختصر و مفید این کتابخانه قدرتمند رو همراه با ارائه چندین مثال کاربردی معرفی کردند:

قسمت اول

قسمت دوم

در تکمیل قسمتهای فوق بنده میخوام مثالی رو در این رابطه براتون بذارم، هدف از ارائه این مثال اتوماتیک سازی یک فرآیند روتین میباشد، به این صورت که در جایی که بنده مشغول به کار هستم یک سری لایسنس آنتی ویروس برای کلاینتها در یک شبکه با مقیاس متوسط تهیه گردیده است، حال یک نسخه رایگان نیز برای کاربرانی که قصد دارند آنتی ویروس را برای سیستم شخصی خود نصب کنند نیز موجود میباشد که نیاز به آپدیت دارد معمولا آپدیتها هر چند روز یکبار یا هر هفته در دو نسخه 64 و 32 بیتی ارائه میشوند، روال معمول برای دریافت آیدیت مراجعه به سایت و دانلود نسخههای مربوطه میباشد.

حال توسط کتابخانه قدرتمند Quartz.NET این فرآیند روتین را به صورت اتوماتیک میخواهیم انجام دهیم، استفاده از کتابخانه ذکر شده سخت نیست همانطور که در دو مطلب قبلی مرتبط ذکر گردیده، تنها پیاده سازی چندین اینترفیس است و بس.

```
namespace SymantecUpdateDownloader
    using System;
    using System.IO;
    using Quartz;
    using Quartz.Impl;
    using System.Globalization;
    public class TestJob : IJob
        public void Execute(IJobExecutionContext context)
            new Download().Scraping();
    public interface ISchedule
        void Run();
    public class TestSchedule : ISchedule
        public void Run()
            DateTimeOffset startTime = DateBuilder.FutureDate(2, IntervalUnit.Second);
            IJobDetail job = JobBuilder.Create<HelloJob>()
                                        .WithIdentity("job1")
                                        .Build();
            ITrigger trigger = TriggerBuilder.Create()
                                              .WithIdentity("trigger1")
                                              .StartAt(startTime)
                                              .WithDailyTimeIntervalSchedule(x =>
x.OnEveryDay().StartingDailyAt(new TimeOfDay(7, 0)).WithRepeatCount(0))
                                              .Build();
            ISchedulerFactory sf = new StdSchedulerFactory();
            IScheduler sc = sf.GetScheduler();
            sc.ScheduleJob(job, trigger);
            sc.Start();
       }
    }
}
```

و همانطور که مشخص است وظیفه تعیین شده و هر روز ساعت 7 اجرا میشود.

مورد بعدی عملیات دانلود فایل میباشد که در ادامه مشاهده خواهید کرد، صفحه ایی که لینک فایلهای دانلود را ارائه داده است دو نسخه مد نظر ما را در ابتدا لیست کرده است و با استفاده از web scraping میسر شده را استخراج کنیم برای این منظور از کتابخانه htmlagilitypack استفاده میکنیم، تطبیق دو مورد(لینک) اول جهت دریافت نسخههای 32 و 64 بیتی به کمک Regular Expression میسر است و همانطور که در شکل زیر مشاهده میکنید از سمت چپ تاریخ به صورت 8 رقم، سه رقم قسمت دوم و ارقام و حروف قسمت سوم است به اضافه یسوند فایل مشخص است :

File Name

20130621-022-v5i32.exe | FTP

```
public class Download
       static WebClient wc = new WebClient();
       static ManualResetEvent handle = new ManualResetEvent(true);
       private DateTime myDate = new DateTime();
       public void Scraping()
           using (WebClient client = new WebClient())
               client.Encoding = System.Text.Encoding.UTF8;
               var doc = new HtmlAgilityPack.HtmlDocument();
               ArrayList result = new ArrayList();
doc.LoadHtml(client.DownloadString("https://www.symantec.com/security response/definitions/download/det
ail.jsp?gid=savce"));
               var tasks = new List<Task>();
               foreach (var href in doc.DocumentNode.Descendants("a").Select(x =>
x.Attributes["href"]))
               1
                   if (href == null) continue;
                   string s = href. Value;
                   Match m = Regex.Match(s, @"http://definitions.symantec.com/defs/(\d{8}-\d{3}-
v5i(32|64)\.exe)");
                   if (m.Success)
                       int month = Int32.Parse(date.Groups[1].Value);
                       int day = Int32.Parse(date.Groups[3].Value);
                       myDate = new DateTime(
                               Int32.Parse(date.Groups[1].Value),
                               Int32.Parse(date.Groups[2].Value)
                               Int32.Parse(date.Groups[3].Value));
                       if (myDate == DateTime.Today)
                       1
                           tasks.Add(DownloadUpdate(m.Value, filename.Value));
                       }
                       else
                       {
                           ;("امروز آیدیت موجود نیست")MessageBox.Show
                       }
                   }
               DownloadTask = Task.WhenAll(tasks);
       private static Task DownloadTask;
       private Task DownloadUpdate(string url, string fileName)
           var wc = new WebClient();
           return wc.DownloadFileTaskAsync(new Uri(url), @"\\10.1.0.15\SymantecUpdate\\" + fileName);
       }
```

}

توضیح کدهای فوق:

ابتدا توسط متد LoadHtml خط 14 صفحه مورد نظر که حاوی لینکها میباشد رو Load میکنیم، سپس توسط یک حلقه foreach خط 16 مقدار خصوصیت href در لینکها به ضط 16 مقدار خصوصیت href در لینکها به صورت زیر میباشد :

http://definitions.symantec.com/defs/20130622-007-v5i32.exe

http://definitions.symantec.com/defs/20130622-007-v5i64.exe

همانطور که مشخص است در دو مورد فوق تنها نام فایل متفاوت میباشد، همانطور که بحث شد برای نام فایلها هم میتوانیم یک Pattern را به صورت زیر داشته باشیم :

 $(\d{8}-\d{3}-v5i(32|64)\.exe)$

در خط 20 نیز عملیات تطبیق تمام hrefهای موجود در صفحه را توسط Regular Expression فوق تطبیق میدهیم، اگر تطبیق با موفقیت انجام پذیرفت باید نام فایل و همچنین تاریخ موجود در نام فایل را نیز توسط دو Regular Expression استخراج کنیم(خط 23 و 24) در ادامه برای جدا کردن مقادیر سال ، ماه ، روز از امکان Groups در Regex استفاده کرده ایم:

```
int year = Int32.Parse(date.Groups[0].Value);
int month = Int32.Parse(date.Groups[1].Value);
int day = Int32.Parse(date.Groups[3].Value);
```

در ادامه تاریخ استخراج شده را با تاریخ روز جاری مقایسه میکنیم اگر مساوی بود عملیات دانلود فایلها توسط یک <u>Task</u> تعریف شده به صورت همزمان بر روی سرور مربوطه دانلود میشوند.

البته لازم به ذکر است که کدهای فوق مسلما نیاز یه Refactoring دارند منتها هدف از ارائه این مثال آشنایی بیشتر با کتابخانههای فوق میباشد.

نکته آخر اینکه برنامه فوق به حالتهای مختلفی میتواند اجرا گردد مثل یک برنامه وب یا یک سرویس ویندوزی و ... ، بهترین حالت یک سرویس ویندوز میباشد که بر روی سرور RUN حالت یک سرویس ویندوز میباشد، ولی در حالت خام در حال حاضر یک ویندوز اپلیکیشن ساده میباشد که بر روی سرور RUN شده است که در آینده به صورت یک سرویس ویندوز ارائه خواهد شد.

نظرات خوانندگان

نویسنده: افشین

تاریخ: ۸:۱ ۱۳۹۲/۰۴/۱۵

یه سئوال دارم که همیشه ذهنم رو مشغول کرده

مگه اینترفیس فقط امضا روالها رو نداره؟ پس یک کلاس نیاز داره که بتونه اون متدها رو پیاده سازی کنه و ما ازش استفاده کنیم غیر از اینه؟

پس در کد زیر

IJobDetail job = JobBuilder.Create<HelloJob>()

مجبوریم از اینترفیس به عنوان متغیر استفاده کنیم؟

نویسنده: سیروان عفیفی تاریخ: ۲۲:۴۲ ۱۳۹۲/۰۴/۱۵

بله به همین صورته،این مطلب رو درباره اینترفیس و این مطلب رو درباره متدهای <u>Generic</u> بخونید، متد Create یک متد Generic است که نام کلاسی رو که اینترفیس IJob و Implement کرده را قبول میکند، و در نهایت مقدار بازگشتی این متد از نوع IJobDetail است.

ارسال PingBack در ASP.NET

نویسنده: وحيد نصيري

عنوان:

٧:۵ ١٣٩٣/٠٢/٠٨ تاریخ:

www.dotnettips.info آدرس:

ASP.Net, MVC, Regular expressions, Html Agility Pack, SEO گروهها:

Pingback یکی از روشهای اطلاع رسانی به سایتهای دیگر در مورد لینک دادن به آنها در سایت خود است. برای مثال من لینکی از یکی از مطالب شما را در متن جاری خودم قرار میدهم. سپس به وسیلهی ارسال یک ping، در مورد انجام اینکار به شما اطلاع رسانی میکنم. حاصل آن عموما قسمت معروف ping-backs سایتها است. این مورد نیز یکی از روشهای مؤثر SEO در گرفتن backlink است و تبلیغ محتوا.

کار کردن با پروتکل Ping-back آنچنان ساده نیست؛ از این جهت که تبادل ارتباطات آن با پروتکل XML-RPC انجام میشود. -XML RPC نیز توسط PHP کارها بیشتر مورد استفاده قرار میگیرد؛ بجای استفاده از یروتکلهای استاندارد وب سرویسها مانند Soap و امثال آن. پیاده سازیهای ابتدایی Pingback نیز مرتبط است به Wordpress معروف که با PHP تهیه شدهاست. در ادامه نگاهی خواهیم داشت به جزئیات پیاده سازی ارسال ping-back توسط برنامههای ASP.NET.

یافتن آدرس وب سرویس سایت پذیرای Pingback

اولین قدم در پیاده سازی Pingback، یافتن آدرسی است که باید اطلاعات مورد نظر را به آن ارسال کرد. این آدرس عموما به دو طریق ارائه میشود:

الف) در هدری به نام x-pingback و یا

ب) در قسمتی از کدهای HTML صفحه به شکل

<link rel="pingback" href="pingback server">

برای مثال اگر به وبلاگهای MSDN دقت کنید، هدر x-pingback را میتوانید در خروجی وب سرور آنها مشاهده کنید:



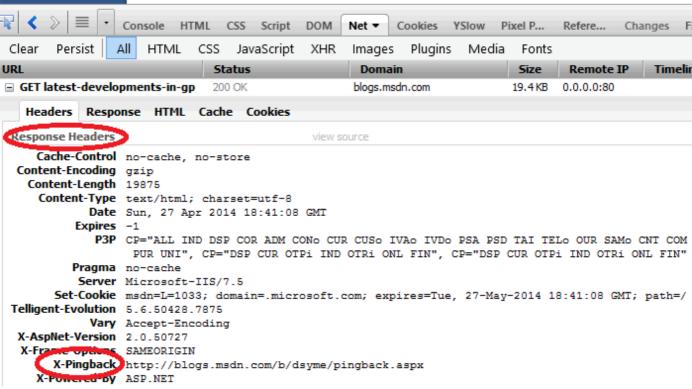
Latest Developments in General Purpose GPU Programming with F#



dsyme 23 Apr 2014 4:06 AM







همانطور که ملاحظه میکنید، نیاز است Response header را آنالیز کنیم.

```
private Uri findPingbackServiceUri()
             var request = (HttpWebRequest)WebRequest.Create(_targetUri);
             request.UserAgent = UserAgent;
             request.Timeout = Timeout;
             request.ReadWriteTimeout = Timeout;
             request.Method = WebRequestMethods.Http.Get;
             request.AutomaticDecompression = DecompressionMethods.GZip | DecompressionMethods.Deflate;
             using (var response = request.GetResponse() as HttpWebResponse)
                 if (response == null) return null;
                 var url = extractPingbackServiceUriFormHeaders(response);
                 if (url != null)
                     return url;
                 if (!isResponseHtml(response))
                      return null:
                 using (var reader = new StreamReader(response.GetResponseStream()))
                      return extractPingbackServiceUriFormPage(reader.ReadToEnd());
                 }
             }
        }
        private static Uri extractPingbackServiceUriFormHeaders(WebResponse response)
             var pingUrl = response.Headers.AllKeys.FirstOrDefault(header =>
                                  header.Equals("x-pingback", StringComparison.OrdinalIgnoreCase) ||
header.Equals("pingback", StringComparison.OrdinalIgnoreCase));
```

```
return getValidAbsoluteUri(pingUrl);
        private static Uri extractPingbackServiceUriFormPage(string content)
             if (string.IsNullOrWhiteSpace(content)) return null;
var regex = new Regex(@"(?s)<link\srel=""pingback""\shref=""(.+?)""",</pre>
RegexOptions.IgnoreCase);
             var match = regex.Match(content);
             return (!match.Success || match.Groups.Count < 2) ? null :</pre>
getValidAbsoluteUri(match.Groups[1].Value);
        private static Uri getValidAbsoluteUri(string url)
             Uri absoluteUri;
             return string.IsNullOrWhiteSpace(url) || !Uri.TryCreate(url, UriKind.Absolute, out
absoluteUri) ? null : absoluteUri;
        private static bool isResponseHtml(WebResponse response)
             var contentTypeKey = response.Headers.AllKeys.FirstOrDefault(header =>
                                           header.Equals("content-type",
StringComparison.OrdinalIgnoreCase));
             return !string.IsNullOrWhiteSpace(contentTypeKey) &&
                      response.Headers[contentTypeKey].StartsWith("text/html",
StringComparison.OrdinalIgnoreCase);
```

نحوهی استخراج آدرس سرویس Pingback یک سایت را در کدهای فوق ملاحظه میکنید.

targetUri، آدرسی است از یک سایت دیگر که در سایت ما درج شدهاست. زمانیکه این صفحه را درخواست میکنیم، targetUri در سایت میکنیم، باشد یا خیر. اگر بلی، همینجا کار پایان مییابد. فقط باید x-pingback حاصل میتواند حاوی کلید getValidAbsoluteUri باشد یا خیر. اگر بلی، همین جهت در متد getValidAbsoluteUri، بررسی بر روی UriKind.Absolute

اگر هدر فاقد کلید x-pingback باشد، قسمت ب را باید بررسی کرد. یعنی نیاز است محتوای Html صفحه را برای یافتن link اگر هدر فاقد کلید rel=pingback باشد، قسمت ب را باید بررسی کنیم. همچنین باید دقت داشت که پیش از اینکار نیاز است حتما بررسی کنیم. همچنین باید دقت داشت که پیش از اینکار نیاز است حتما بررسی کنیم به یک فایل 2 گیگابایتی SQL Server درج شدهاست. در این حالت نباید ابتدا 2 گیگابایت فایل دریافت شود و سپس بررسی کنیم که آیا محتوای آن حاوی link rel=pingback است یا خیر. اگر محتوای ارسالی از نوع text/html بود، آنگاه کار دریافت محتوای لینک انجام خواهد شد.

ارسال Ping به آدرس سرویس Pingback

اكنون كه آدرس سرويس pingback يك سايت را يافتهايم، كافي است ping ايي را به آن ارسال كنيم:

```
public void Send()
             var pingUrl = findPingbackServiceUri();
             if (pingUrl == null)
                 throw new NotSupportedException(string.Format("{0} doesn't support pingback.",
_targetUri.Host));
             sendPing(pingUrl);
        }
        private void sendPing(Uri pingUrl)
             var request = (HttpWebRequest)WebRequest.Create(pingUrl);
             request.UserAgent = UserAgent;
             request.Timeout = Timeout;
             request.ReadWriteTimeout = Timeout;
            request.Method = WebRequestMethods.Http.Post;
request.ContentType = "text/xml";
             request.ProtocolVersion = HttpVersion.Version11;
            makeXmlRpcRequest(request);
            using (var response = (HttpWebResponse)request.GetResponse())
                 response.Close();
```

```
}
}
private void makeXmlRpcRequest(WebRequest request)
     var stream = request.GetRequestStream();
     using (var writer = new XmlTextWriter(stream, Encoding.ASCII))
          writer.WriteStartDocument(true);
          writer.WriteStartElement("methodCall");
writer.WriteElementString("methodName", "pingback.ping");
writer.WriteStartElement("params");
          writer.WriteStartElement("param");
writer.WriteStartElement("value");
          writer.WriteElementString("string", Uri.EscapeUriString(_sourceUri.ToString()));
          writer.WriteEndElement();
          writer.WriteEndElement();
          writer.WriteStartElement("param");
writer.WriteStartElement("value");
writer.WriteElementString("string", Uri.EscapeUriString(_targetUri.ToString()));
          writer.WriteEndElement();
          writer.WriteEndElement();
          writer.WriteEndElement();
          writer.WriteEndElement();
     }
}
```

اینبار HttpWebRequest تشکیل شده از نوع post است و نه get. همچنین مقداری را که باید ارسال کنیم نیاز است مطابق پروتکل XML-RPC استفاده کرد و یا مطابق XML-RPC باشد. برای کار با XML-RPC در دات نت یا میتوان از کتابخانهی XML-RPC.Net راست کار با Sommuting's کرد و یا مطابق کدهای فوق، دستورات آنرا توسط یک XmlTextWriter کنار هم قرار داد و نهایتا در درخواست Post ارسالی درج کرد. در اینجا sourceUri آدرس صفحهای در سایت ما است که targetUri ایی (آدرسی از سایت دیگر) در آن درج شدهاست. در یک

سپس سایت دریافت کنندهی ping، ابتدا sourceUri را دریافت میکند تا عنوان آنرا استخراج کند و همچنین بررسی میکند که آیا targetUri، در آن درج شدهاست یا خیر (آیا spam است یا خیر)؟

تا اینجا اگر این مراحل را کنار هم قرار دهیم به کلاس Pingback ذیل خواهیم رسید:

pinback، صرفا این دو آدرس به سرویس دریافت کنندهی pingback ارسال میشوند.

Pingback.cs

نحوهی استفاده از کلاس Pingback تهیه شده

کار ارسال Pingback عموما به این نحو است: هر زمانیکه مطلبی یا یکی از نظرات آن، ثبت یا ویرایش میشوند، نیاز است Pingbackهای آن ارسال شوند. بنابراین تنها کاری که باید انجام شود، استخراج لینکهای خارجی یک صفحه و سپس فراخوانی متد Send کلاس فوق است.

یافتن لینکهای یک محتوا را نیز می توان مانند متد extractPingbackServiceUriFormPage فوق، توسط یک Regex انجام داد و یا حتی با استفاده از کتابخانهی معروف HTML Agility Pack :

عنوان: رشته ها و پردازش متن در دات نت به زبان ساده

نویسنده: علی یگانه مقدم

تاریخ: ۱۹:۳۵ ۱۳۹۳/۱۱/۲۸ www.dotnettips.info

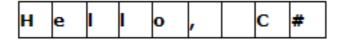
گروهها: C#, Regular expressions, .NET, string, Performance

رشته، مجموعهای از کاراکترهاست که پشت سرهم، در مکانی از حافظه قرار گرفتهاند. هر کاراکتر حاوی یک شماره سریال در جدول یونیکد هست. به طور پیش فرض دات نت برای هر کاراکتر (نوع داده char) شانزده بیت در نظر گرفته است که برای 65536 کاراکتر کافی است.

برای نگهداری از رشتهها و انجام عملیات بر روی آنها در دات نت از نوع system.string استفاده میکنیم:

```
string greeting = "Hello, C#";
```

که در این حالت مجموعهای از کاراکترها را ایجاد خواهد کرد:



اتفاقاتی که در داخل کلاس string رخ میدهد بسیار ساده است و ما را از تعریف []char بینیاز میکند تا مجبور نشویم خانههای آرایه را به ترتیب پر کنیم. از معایب استفاده از آرایه char میتوان موارد زیر را برشمارد:

خانههای آن یک ضرب پر نمیشوند بلکه به ترتیب، خانه به خانه پر میشوند.

قبل از انتساب متن باید باید از طول متن مطمئن شویم تا بتوانیم تعداد خانهها را بر اساس آن ایجاد کنیم.

همه عملیات آرایهها از پر کردن ابتدای کار گرفته تا هر عملی، نیاز است به صورت دستی صورت بگیرد و تعداد خطوط کد برای هر کاری هم بالا میرود.

البته استفاده از string هم راه حل نهایی برای کار با متون نیست. در انتهای این مطلب مورد دیگری را نیز بررسی خواهیم کرد. از ویژگی دیگر رشتهها این است که آنها شباهت زیادی به آرایهای از کاراکترها دارند؛ ولی اصلا شبیه آنها نیستند و نمیتوانید به صورت یک آرایه آنها را مقداردهی کنید. البته کلاس string امکاناتی را با استفاده از indexer [] مهیا کرده است که میتوانید بر اساس اندیسها به کاراکترها به صورت جداگانه دسترسی داشته باشید ولی نمیتوانید آنها را مقدار دهی کنید. این اندیسها از 0 تا طول آن length-1 ادامه دارند.

```
string str = "abcde";
char ch = str[1]; // ch == 'b'
str[1] = 'a'; // Compilation error!
ch = str[50]; // IndexOutOfRangeException
```

همانطور که میدانیم برای مقداردهی رشتهها از علامتهای نقل قول "" استفاده میکنیم که باعث میشود اگر بخواهیم علامت " را در رشتهها داشته باشیم نتوانیم. برای حل این مشکل از علامت \ استفاده میکنیم که البته باعث استفاده از بعضی کاراکترهای خاص دیگر هم میشود:

```
string a="Hello \"C#\"";
string b="Hello \r\n C#"; //مساوی با اینتر
string c="C:\\a.jpg"; /-مسیردهی// چاپ خود علامت
```

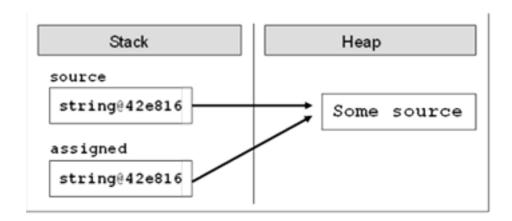
البته اگر از علامت @ در قبل از رشته استفاده شود علامت \ بی اثر خواهد شد.

```
string c=@"C:\a.jpg";// == "C:\\a.jpg"
```

مقداردهی رشتهها و پایدار (تغییر ناپذیر) بودن آنها Immutable

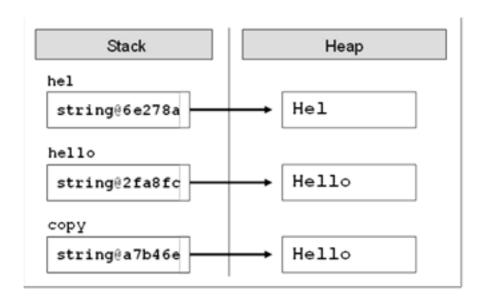
رشتهها ساختاری پایدار هستند؛ به این معنی که به صورت reference مقداردهی میشوند. موقعی که شما مقداری را به یک رشته انتساب میدهید، مقدار متغیر در String pool یا لینک در Heap ذخیره میشوند و اگر همین متغیر را به یک متغیر دیگر انتساب دهیم، متغیر جدید مقدار آن را دیگر در حافظه پویا (داینامیک) Heap به عنوان مقدار جدید ذخیره نخواهد کرد؛ بلکه تنها یک pointer خواهد بود که به آدرس حافظه متغیر اولی اشاره میکند. به مثال زیر دقت کنید. متغیر some source مقدار assign را خخیره میکند و بعد همین متغیر، به متغیر assign انتساب داده میشود؛ ولی مقداری جابجا نمیشود. بلکه متغیر assign به آدرسی در حافظه اشاره میکند که متغیر source اشاره میکند. هرگاه که در یکی از متغیرها، تغییری رخ دهد، همان متغیری که تغییر کرده است، به آدرس جدید با محتوای تغییر داده شده اشاره میکند.

```
string source = "Some source";
string assigned = source;
```

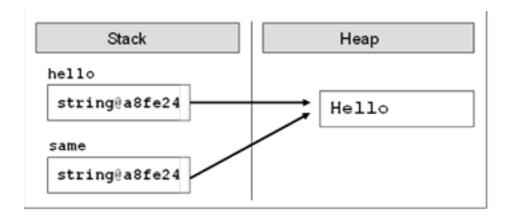


این ویژگی نوع reference فقط برای ساختارهای Immutable به معنی پایدار رخ میدهد و نه برای ساختارهای ناپایدار (تغییر پذیر) mutable؛ به این خاطر که آنها مقادیرشان را مستقیما تغییر میدهند و اشارهای در حافظه صورت نمیگیرد.

```
string hel = "Hel";
string hello = "Hello";
string copy = hel + "lo";
```



```
string hello = "Hello";
string same = "Hello";
```



برای اطلاعات بیشتر در این زمینه این لینک را مطالعه نمایید.

مقايسه رشتهها

برای مقایسه دو رشته میتوان از علامت == یا از متد Equals استفاده نماییم. در این حالت به خاطر اینکه کد حروف کوچک و بزرگ متفاوت اشیری بر مقایسه ما نگذارند و #c بزرگ متفاوت است، مقایسه ما نگذارند و #c برای اینکه حروف کوچک و بزرگ تاثیری بر مقایسه ما نگذارند و #c برابا #C برابر بدانند باید از متد Equals به شکل زیر استفاده کنیم:

برای اینکه بزرگی و کوچکی اعداد را مشخص کنیم از علامتهای < و > استفاده میکنیم ولی برای رشتهها از متد CompareTo بهره میبریم که چینش قرارگیری آنها را بر اساس حروف الفبا مقایسه میکند و سه عدد، میتواند خروجی آن باشند. اگر 0 باشد یعنی برابر هستند، اگر -1 باشد رشته اولی قبل از رشته دومی است و اگر 1 باشد رشته دومی قبل از رشته اولی است.

```
string score = "sCore";
string scary = "scary";

Console.WriteLine(score.CompareTo(scary));
Console.WriteLine(scary.CompareTo(score));
Console.WriteLine(scary.CompareTo(scary));

// Console output:
// 1
// -1
// 0
```

اینبار هم برای اینکه حروف کوچک و بزرگ، دخالتی در کار نداشته باشند، میتوانید از داده شمارشی StringComparison در متد ایستای (string.Compare(s1,s2,StringComparison استفاده نمایید؛ یا از نوع دادهای boolean برای تعیین نوع مقایسه استفاده کنید.

```
string alpha = "alpha";
string score1 = "sCorE";
string score2 = "score";

Console.WriteLine(string.Compare(alpha, score1, false));
Console.WriteLine(string.Compare(score1, score2, false));
Console.WriteLine(string.Compare(score1, score2, true));
```

نکته : برای مقایسه برابری دو رشته از متد Equals یا == استفاده کنید و فقط برای تعیین کوچک یا بزرگ بودن از Equals استفاده نید و فقط برای تعیین کوچک یا بزرگ بودن از Equals استفاده نمایید. دلیل آن هم این است که برای مقایسه از فرهنگ culture فعلی سیستم استفاده میشود و نظم جدول یونیکد را رعایت نمیکنند و ممکن است بعضی رشتههای نابرابر با یکدیگر برابر باشند. برای مثال در زبان آلمانی دو رشته "SS" و "ß" با یکدیگر برابر هستند.

عبارات با قاعده Regular Expression

این عبارات الگوهایی هستند که قرار است عبارات مشابه الگویی را در رشتهها پیدا کنند. برای مثال الگوی +[9-20-A] مشخص میکند که رشته مورد نظر نباید خالی باشد و حداقل با یکی از حروف بزرگ یا اعداد پرشده باشد. این الگوها میتوانند برای واکشی دادهها یا قالبهای خاص در رشتهها به کار بروند. برای مثال شماره تماسها ، پست الکترونیکی و ...

در <u>اینجا</u> میتواند نحوهی الگوسازی را بیاموزید. کد زیر بر اساس یک الگو، شماره تماسهای مورد نظر را یافته و البته با فیلتر گذاری آنها را نمایش میدهد:

```
string doc = "Smith's number: 0898880022\nFranky can be " +
    "found at 0888445566.\nSteven's mobile number: 0887654321";
string replacedDoc = Regex.Replace(
    doc, "(08)[0-9]{8}", "$1*******");
Console.WriteLine(replacedDoc);
// Console output:
// Smith's number: 08********
// Franky can be found at 08*******
// Steven' mobile number: 08********
```

سه شماره تماس در رشته ی بالا با الگوی ما همخوانی دارند که بعد با استفاده از متد replace در شی Regex عبارات دلخواه خودمان را جایگزین شماره تماسها خواهیم کرد. الگوی بالا شماره تماسهایی را میابد که با 08 آغاز شدهاند و بعد از آن 8 عدد دیگر از 0 تا 9 قرار گرفتهاند. بعد از اینکه متن مطابق الگو یافت شد، ما آن را با الگوی ********** جایگزین می کنیم که علامت \$ دیگر از 0 تا 9 قرار گرفتهاند. بعد از اینکه متن مطابق الگو یافت شد، ما آن را با الگوی ********* جایگزین می کنیم که علامت \$ یک واهده ایک گروه حساب میشود و اولین پرانتر 1\$ و دومین پرانتز یا گروه میشود 2\$ که در عبارت بالا (08) میشود 1\$ و به جای مابقی الگو، 8 علامت ستاره نمایش داده میشود.

اتصال رشتهها در Loop

برای اتصال رشتهها ما از علامت + یا متد ایستای string.concat استفاده می کنیم ولی استفاده ی از آن در داخل یک حلقه باعث کاهش کارآیی برنامه خواهد شد. برای همین بیایید ببینم در حین اتتقال رشتهها در حافظه چه اتفاقی رخ میدهد. ما در اینجا دو رشته str1 و str2 داریم که عبارات "super" و "star" را نگه داری می کنند و در واقع دو متغیر هستند که به حافظه ی پویای Heap اشاره می کنند. اگر این دو را با هم جمع کنیم و نتیجه را در متغیر result قرار دهیم، سه متغیر میشوند که هر کدام به حافظه ی جداگانه در heap اشاره می کنند. در واقع برای این اتصال، قسمت جدیدی از حافظه تخصصیص داده شده و مقدار جدید در آن نشسته است. در این حالت یک متغیر جدید ساخته شد که به آدرس آن اشاره می کند. کل این فرآیند یک فرآیند کاملا زمانبر است که با تکرار این عمل موجب از دست دادن کارآیی برنامه می شود؛ به خصوص اگر در یک حلقه این کار صورت بگیرد.

سیستم دات نت همانطور که میدانید شامل <u>GC</u> یا سیستم خودکار پاکسازی حافظه است که برنامه نویس را از dispose کردن بسیاری از اشیاء بی نیاز میکند. موقعیکه متغیری به قسمتی از حافظه اشاره میکند که دیگر بلا استفاده است، سیستم GC به صورت خودکار آنها را پاکسازی میکند که این عمل زمان بر هم خودش موجب کاهش کارآیی میشود. همچنین انتقال رشتهها از یک مکان حافظه به مکانی دیگر، باز خودش یک فرآیند زمانبر است؛ به خصوص اگر رشته مورد نظر طولانی هم باشد. مثال عملی: در تکه کد زیر قصد داریم اعداد 1 تا 20000 را در یک رشته الحاق کنیم:

```
Console.WriteLine(dt);
Console.WriteLine(DateTime.Now);
Console.ReadKey();
```

کد بالا تاز زمان نمایش کامل، بسته به قدرت سیستم ممکن است یکی دو ثانیه طول بکشد. حالا عدد را به 200000 تغییر دهید (یک صفر اضافه تر). برنامه را اجرا کنید و مجددا تست بزنید. در این حالت چند دقیقه ای بسته به قدرت سیستم زمان خواهد برد؛ مثلا دو دقیقه یا سه دقیقه یا کمتر و بیشتر.

عملیاتی که در حافظه صورت میگیرد این چند گام را طی میکند:

قسمتی از حافظه به طور موقت برای این دور جدید حلقه، گرفته میشود که به آن بافر میگوییم.

رشته قبلی به بافر انتقال میابد که بسته به مقدار آن زمان بر و کند است؛ 5 کیلو یا 5 مگابایت یا 50 مگابایت و ...

شماره تولید شده جدید به بافر چسبانده میشود.

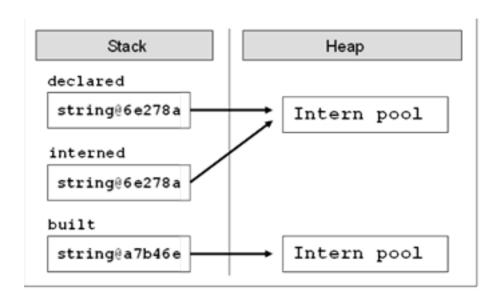
بافر به یک رشته تبدیل میشود وجایی برای خود در حافظه Heap میگیرد.

حافظه رشته قدیمی و بافر دیگر بلا استفاده شدهاند و توسط GC پاکسازی میشوند که ممکن است عملیاتی زمان بر باشد.

String Builder

این کلاس ناپایدار و تغییر پذیر است. به کد و شکل زیر دقت کنید:

```
string declared = "Intern pool";
string built = new StringBuilder("Intern pool").ToString();
```



این کلاس دیگر مشکل الحاق رشتهها یا دیگر عملیات پردازشی را ندارد. بیایید مثال قبل را برای این کلاس هم بررسی نماییم:

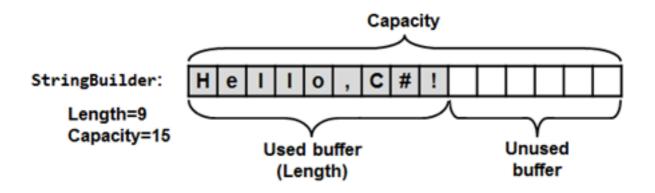
اکنون همین عملیات چند دقیقهای قبل، در زمانی کمتر، مثلا دو ثانیه انجام میشود. حال این سوال پیش می آید مگر کلاس stringbuilder چه میکند که زمان یردازش آن قدر کوتاه است؟

همانطور که گفتیم این کلاس mutable یا تغییر پذیر است و برای انجام عملیاتهای ویرایشی نیازی به ایجاد شیء جدید در حافظه ندارد؛ در نتیجه باعث کاهش انتقال غیرضروری دادهها برای عملیات پایهای چون الحاق رشتهها میگردد.

stringbuilder شامل یک بافر با ظرفیتی مشخص است (به طور پیش فرض 16 کاراکتر). این کلاس آرایههایی از کاراکترها را پیاده سازی میکند که برای عملیات و پردازشهایش از یک رابط کاربرپسند برای برنامه نویسان استفاده میکند. اگر تعداد کاراکترها کمتر از 16 باشد مثلا 5 ، فقط 5 خانه آرایه استفاده میشود و مابقی خانهها خالی میماند و با اضافه شدن یک کاراکتر جدید، دیگر شیء جدیدی در حافظه درست نمیشود؛ بلکه در خانه ششم قرار میگیرد و اگر تعداد کاراکترهایی که اضافه میشوند باعث شود از 16 کاراکتر رد شود، مقدار خانهها دو برابر میشوند؛ هر چند این عملیات دو برابر شدن resizing عملیاتی کند است ولی این اتفاق به ندرت رخ میدهد.

کد زیر یک آرایه 15 کاراکتری ایجاد میکند و عبارت #Hello C را در آن قرار میدهد.

```
StringBuilder sb = new StringBuilder(15);
sb.Append("Hello, C#!");
```



در شکل بالا خانه هایی خالی مانده است Unused و جا برای کاراکترهای جدید به اندازه خانههای unused هست و اگر بیشتر شود همانطور که گفتیم تعداد خانهها 2 برابر میشوند که در اینجا میشود 30.

استفاده از متد ایستای string.Format

از این متد برای نوشتن یک متن به صورت قالب و سیس جایگزینی مقادیر استفاده میشود:

```
DateTime date = DateTime.Now;
string name = "David Scott";
string task = "Introduction to C# book";
string location = "his office";

string formattedText = String.Format(
    "Today is {0:MM/dd/yyyy} and {1} is working on {2} in {3}.",
    date, name, task, location);
Console.WriteLine(formattedText);
```

در کد بالا ابتدا ساختار قرار گرفتن تاریخ را بر اساس الگو بین {} مشخص میکنیم و متغیر date در آن قرار میگیرد و سپس برای (میگیرند. (ate),{2},{1}} به ترتیب قرار گیری آنها متغیرهای name,last,location قرار میگیرند.

از ()ToString. هم میتوان برای فرمت بندی خروجی استفاده کرد؛ مثل همین عبارت MM/dd/yyyy در خروجی نوع داده تاریخ و زمان.

نظرات خوانندگان

نویسنده: شهروز جعفری

تاریخ: ۲۸:۱۰ ۱۸:۱۰ ۱۸:۱۸

یک سوال منظور از Gac اینجا چیه؟

نویسنده: علی یگانه مقدم تاریخ: ۱۸:۴۸ ۱۳۹۳/۱۱/۲۹

ممنون که گوشزد کردید؛ عذر میخوام. مطلب ویرایش شد. منظور GC بود. بنده اشتباها نوشتم GAC.